

REAL-TIME TRANSLATOR (RTT)

Hệ thống Phiên dịch & Thuyết minh Trực tiếp 100% Cục bộ trên Windows

Báo cáo Kỹ thuật Sản phẩm
Nền tảng: Windows 11 | GPU CUDA
Kiến trúc: Local AI Pipeline

1. TỔNG QUAN & TÍNH CẤP THIẾT CỦA DỰ ÁN

Thách thức thực tế: Khi xem video (YouTube, Netflix), học trực tuyến hoặc họp đa quốc gia (Zoom, Teams), người dùng gặp rào cản ngôn ngữ lớn. Các dịch vụ Cloud API hiện tại bị giới hạn bởi: (1) Chi phí cao, (2) Độ trễ truyền tải lớn, (3) Nguy cơ rò rỉ dữ liệu âm thanh cá nhân.

Giải pháp RTT: Ứng dụng Desktop chạy **100% Offline / Local**, tự động bắt luồng âm thanh hệ thống (System Audio Loopback), nhận dạng giọng nói, dịch thuật và hiển thị phụ đề nổi hoặc **thuyết minh giọng nói đề (Cabin Dubbing Mode)** với độ trễ thời gian thực.

2. KIẾN TRÚC HỆ THỐNG & ĐA LUỒNG (PIPELINE ARCHITECTURE)

Hệ thống vận hành theo luồng dữ liệu liên tục xử lý qua các mô hình AI cục bộ chuyên biệt:

```
[Âm thanh Hệ thống (WASAPI Loopback)] → Resample 16kHz Mono → Silero VAD
                                     |
                                     ↓
PySide6 Overlay ← NLLB-200 (MT) ← faster-whisper (STT) ←
                                     |
                                     ↓
                               Piper TTS Dubbing → [Audio Ducking: Giảm 82% âm lượng app khác]
```

Mô hình 5 luồng xử lý song song (Concurrent Multi-Threading):

1. Audio Capture Thread (audio.py)

Bắt luồng âm thanh hệ thống qua WASAPI Loopback. Resample về 16kHz float32 mono bằng PyAV. Bơm clock im lặng giả để không treo luồng khi không có tiếng.

2. STT Thread (stt.py)

Kết hợp Silero VAD lọc giọng nói và faster-whisper nhận dạng. Áp dụng thuật toán chốt câu sớm (Early-Commit) cắt theo dấu câu.

3. MT Thread (translate.py)

Mô hình NLLB-200 (CTranslate2) xử lý hàng đợi dịch. Dịch bản nháp (Partial, beam=1) độ trễ ~0.8s và dịch chốt (Commit, beam=4) chính xác cao.

4. Dubbing & Control Thread (dub.py)

Piper TTS phát giọng đọc tiếng Việt. Kết hợp Windows Core Audio API (pycaw) né tiếng (Ducking) và tự điều chỉnh tốc độ đọc (Catch-Up Pacing).

5. Qt Main UI Thread (overlay.py / app.py)

Quản lý phụ đề nổi PySide6 không viền (frameless), luôn ở trên cùng (always-on-top), cho phép click xuyên qua (click-through) và menu System Tray.

3. BẢNG PHÂN CÔNG MODULE & MÔ HÌNH AI CỐT LÕI

Module Source	Công nghệ / Model	Chức năng Kỹ thuật Cốt lõi
rtt/audio.py	pyaudiowatch PyAV	Capture WASAPI Loopback không cần cấp âm thanh ảo; Resample luồng 16kHz Mono.
rtt/stt.py	Whisper Silero VAD	Nhận dạng giọng nói phát hiện từ thời gian thực; Thuật toán Punctuation Early-Commit.
rtt/translate.py	NLLB-200 CTranslate2	Dịch tự động 200 ngôn ngữ (tối ưu tiếng Việt); Định dạng float16/int8 tiết kiệm VRAM.
rtt/dub.py	Piper TTS pycaw	Thuyết minh giọng máy tiếng Việt; Tự giảm âm lượng app khác và ép tốc độ đọc 1.0x-1.45x.
rtt/overlay.py	PySide6 QPainter	Cửa sổ phụ đề trong suốt, chữ vẽ viền đen bóng (_OutlinedLabel) chống chói trên mọi nền.

REAL-TIME TRANSLATOR (RTT)

Đột phá Kỹ thuật, Đánh giá Hiệu năng & Hướng phát triển

Báo cáo Kỹ thuật Sản phẩm

Trang 2 / 2

4. CÁC ĐỘT PHÁ KỸ THUẬT & THUẬT TOÁN ĐỔI MỚI

1. Thuật toán Punctuation Early-Commit (Ngắt câu thông minh):

- Vấn đề:** Khi nghe diễn giả nói liên tục không ngắt nghỉ (TED Talks, Tin tức), Whisper truyền thống phải đợi im lặng mới chốt câu, gây tích tụ buffer và trễ nặng hàng chục giây.
- Giải pháp RTT:** Kiểm tra đồng thời im lặng VAD ($\geq 0.45s$) HOẶC dấu câu (. ! ? ...) kết hợp đoạn thoại phía sau ($\geq 0.35s$ và ≥ 3 từ). Khi đủ điều kiện, hệ thống chốt câu ngay lập tức kèm lề an toàn 0.3s, giúp bản dịch xuất hiện từng câu mượt mà theo thời gian thực.

2. Thuật toán Dynamic Pacing Catch-Up (Thuyết minh bám đuổi):

- Trong chế độ Cabin (- - dub), câu dịch tiếng Việt có thể dài hơn câu gốc tiếng Anh. Hệ thống tự động tính toán độ dài hàng đợi âm thanh: nếu câu dịch bị dồn tích, tốc độ đọc Piper TTS được đẩy linh hoạt từ 1.0x lên đến 1.45x để thuyết minh đuổi kịp tiến độ video.

3. Per-App Audio Ducking & Feedback Gate (Chống lặp âm thanh):

- Audio Ducking:** Khi giọng thuyết minh phát ra, module pycaw giao tiếp với Windows Core Audio Session tự động ép âm lượng trình duyệt/media player xuống **18%**, giúp tiếng thuyết minh nghe rõ ràng như phiên dịch cabin chuyên nghiệp.
- Feedback Gate:** Tự động ngắt thu âm Loopback trong khoảng thời gian TTS đang phát ra loa để tránh máy tự thu lại giọng đọc của chính mình tạo thành vòng lặp vô tận.

4. Tối ưu hóa Bộ nhớ VRAM & DLL Resolution (Tự động hóa CUDA):

- Nạp model NLLB-200 (int8_float16) trước Whisper để tránh tràn VRAM ngầm. Tự động truy xuất thư viện CUDA/cuDNN từ các pip wheel (cudalibs.py) giúp người dùng không cần cài thủ công CUDA Toolkit. Hỗ trợ JIT compile cho GPU thế hệ mới.

5. ĐÁNH GIÁ HIỆU NĂNG & KẾT QUẢ THỰC NGHIỆM

Hệ thống được thử nghiệm thực tế trên cấu hình PC tầm trung (NVIDIA RTX GPU / Intel Core i5):

Chỉ số Hiệu năng (Metric)	Kết quả Thực nghiệm	Ý nghĩa / Đánh giá Kỹ thuật
Độ trễ Dịch nháp (Partial Latency)	~0.8 giây	Phụ đề nháp hiện tức thì khi người nói đang cất lời.
Độ trễ Chốt câu (Commit Latency)	~1.0 - 4.0 giây	Bản dịch hoàn chỉnh đạt độ chính xác ngữ pháp cao nhất.
Tốc độ xử lý CUDA (VRAM ~2.8GB)	Nhanh hơn ~20 lần CPU	Chạy mượt đồng thời Whisper Small + NLLB 600M trên GPU 4GB.
Mức độ Bảo mật & Chi phí	100% Offline / 0 VNĐ	Không gửi audio ra ngoài, đáp ứng yêu cầu bảo mật tuyệt đối.

6. KẾT LUẬN & ĐỊNH HƯỚNG PHÁT TRIỂN

✓ Giá trị Đóng góp của Dự án

RTT giải quyết triệt để bài toán dịch đa phương tiện thời gian thực trên máy tính cá nhân. Việc kết hợp STT + MT + TTS + Audio Control hoàn toàn offline mang lại trải nghiệm tương đương các giải pháp phần cứng đắt tiền.

🚀 Hướng phát triển Tiếp theo

- Tích hợp Process-Exclusive Loopback (nghe tiếng gốc & tiếng dịch riêng kênh).
- Tích hợp PhoWhisper cho âm thanh đầu vào tiếng Việt.
- Đóng gói installer hoàn chỉnh với giao diện GUI Cài đặt.